GLOBAL HR FORUM

글로벌인재포럼 2026

AI 시대의 법적 책임 소재와 제도적 맹점 보완

. (분산된 책임을 다시 보이게 하는 법 — 증명·보험·인간 존엄의 재설계)

강민구

법무법인 도울 대표 변호사/전 국가AI위원회 법.제도 분과위원장

교육부 한국경제신문 KRIVET 한국직업능력연구원

01 문제 제기

「AI가 잘못했다」는 답이 아니라 질문의 시작

판단의 실질은 기계로 옮겨 갔지만, 책임질 수 있는 존재는 여전히 사람과 법인뿐이다



다수 관여자

개발사·데이터 제공자·통합자·배포자·이용자가 겹겹이 관여 — 모두가 「작은 기여」만 주장



예견가능성의 붕괴

확률적·창발적 출력 — 엄격히 보면 아무도 과실 없고, 느슨히 보면 AI 사용 자체가 과실



증거의 편재

원인을 밝힐 데이터·모델·로그는 모두 사업자 서버에 — 피해자는 결과만 안다

→ 「책임의 공백」: 피해자는 누구에게도 묻지 못하고, 사업자는 어디까지 책임질지 모른다

02 AI 사고의 유형

오작동·환각·편향을 법률요건으로 번역해야 한다

1 **물리행동형**

자율주행 충돌, 로봇 사고 → 제조물 결함·운전자 과실 경합

2 **정보오류형(환각)**

챗봇 허위 안내, 가짜 판례 → 표시상 결함·전문가 검증 의무

3 **판단편향형**

채용·대출·보험 차별 → 간접차별 증명·집단적 구제

4 **권한초과형**

에이전트 무단 결제·오발송 → 의사표시 귀속·권한설계 과실

5 **보안침해형**

프롬프트 인젝션, 기밀 유출 → 제3자 개입과 인과관계

6 **오용유도형**

딥페이크 사기 → 고의범·공급자 방조

7 **운영관리형**

업데이트 후 성능 저하 방치 → 출시 후 관리의무

공통점: 원인이 개발·배포·운영·이용 단계에 흩어지고, 출시 후에도 위험이 계속 변한다(동적 제품)

03 책임 배분의 원칙

책임은 「가장 적절한 위험통제자」에게

기반모델 개발사 | 데이터 제공자 | 통합·미세조정 | 배포 사업자 | 운영 기업 | 전문 사용자 | 최종 이용자

책임 사슬(AI 가치사슬) — 피해자에게는 연대책임, 내부적으로는 기여도에 따른 구상

1. 통제가능성
2. 위험창출
3. 경제적 이익
4. 전문성·정보접근성
5. 예견·회피가능성
6. 기록 보존 지위

※ AI에 법인격을 주면 배후 경제주체의 「책임 세탁」 창구가 된다 — 책임의 종착점은 언제나 사람 또는 법인

「AI를 조심해서 쓸 의무」가 아니라 용도별 표준주의의무로

예견의 대상을 바꾼다
개별 출력이 아니라 「그러한 유형의 위험」을 예견 대상으로 삼아야 과실책임이 작동한다.

환각은 이미 알려진 위험
검증 없이 의료 소견·법률 조언·신용 거절·자동 제어에 연결했다면 예견 가능한 위험을 회피하지 않은 것.

심리의 중심
결과책임과 면책의 양극단 사이 — 「합리적 대체설계·대체절차가 있었는가」

의료 AI	임상 검증, 의사의 검토 절차
법률 AI	판례·법령 인용 검증
채용 AI	집단별 결과 테스트, 이의제기 절차
자율주행	운행가능영역(ODD), 업데이트 관리

용도별 표준주의의무의 예

무과실책임이지만, AI 앞에서 세 개의 관문에 막힌다

1

「동산」의 관문

제조물 = 제조·가공된 동산(제2조 제1호). 탑재형 AI는 포섭되나, 독립 소프트웨어·클라우드 AI는 회색지대

2

「공급 시점」의 관문

출시 후 업데이트·재학습으로 위험이 변함 → 결함 시점·개발위험 항변·시효 기산점이 모두 흔들림

3

「추정 요건」의 관문

결함 추정(제3조의2)의 「실질적 지배영역」은 복층 공급망에서 특정 곤란, 「AI는 원래 틀린다」는 항변과 긴장

활로: 표시상 결함

설계 결함이 없어도, 합리적 설명·지시·경고를 하지 않았다면 책임 인정(대법원 2003. 9. 5. 선고 2002다17333 판결).

「오토파일럿」·「AI 의사」 같은 명칭이 경계를 풀게 만들면 AI 마케팅에 직접 닿는다.

실무: 제조물책임과 민법 제750조를 예비적으로 병합 — 하나의 구성에서 패소하지 않게

06 해외 사례

법원은 「AI가 한 일」이라는 항변을 받아들이지 않는다

33%

테슬라 오토파일럿 사망사고 배심평결(2025)에서 인정된 제조사 책임 비율

징벌적 배상 포함 총 2억 4,300만 달러. 운전자의 명백한 부주의에도 설계·표시 결함이 비율적으로 인정. 2026. 2. 평결 유지(항소 예정).

에어캐나다 챗봇(2024)

챗봇이 별도 주체라는 항변 배척 → AI의 발화는 배치한 사업자의 발화

모블리 v. 워크데이(2024~25)

AI 채용 도구 공급사가 고용주의 「대리인」으로 직접 책임 가능 → 집단소송 예비 인가

마타 v. 아비앙카(2023)

AI가 만든 가짜 판례 제출 변호사 제재 → 전문가의 검증의무. 국내에서도 2026년 유사 사례 잇따라

※ 외국 판결·평결은 비교법 자료이며 국내 재판규범이 아님

07 형사책임

AI 뒤의 누구를, 어떤 요건으로 처벌할 것인가



책임주의 유지

민사 과실 ≠ 형사 과실. 허용된 위험·신뢰의 원칙을 통과한 구체적 주의의무 위반만



도덕적 완충지대 경계

시스템 결함을 말단 운용자가 떠안는 구조 차단 — 개입 가능성·정보·훈련을 과실 판단에 반영



조직책임 모델

중대재해처벌법처럼 경영책임자의 위험관리체계 구축·이행 의무 — 고영향·생명신체 영역에 한정

고의적 악용(딥페이크·음성 복제 사기)은 엄정 처벌 / 일반적 사고의 예방은 인증·사고조사·리콜·보험·과징금으로

08 기존 법체계의 구조적 맹점

사전 규제(공법)와 사후 구제(사법)가 끊어져 있다

공법상 의무
AI 기본법 투명성·안전성·고영향 책무·영향평가 → 과태료·시정명령

연결 고리 없음
의무 위반을 알아도 배상에 이르지 못함

사법상 구제
민법·제조물책임법 → 피해자가 과실·결함·인과를 모두 증명

증거 편재
로그가 없거나 덮어써지면 본안이 무너진다

형식적 인간 감독
결재는 사람이, 판단은 AI가 — 「완전 자동화」 요건 회피

인간 노동 전제
알고리즘 노무관리·학습형 로봇·임금 기반 사회보험의 한계

09 국내외 입법 동향

EU는 사전 규제를 늦추고, 사후 배상을 먼저 넓혔다

2024. 3.

개인정보 보호법 제37조의2 시행(자동화 결정 거부·설명권)

2025. 10.

EU AI 책임지침 공식 철회

2026. 1. 22.

인공지능기본법·시행령 시행

2026. 7.

개정 AI 기본법 시행(21일) / EU 옴니버스 발효(27일)

2026. 12. 9.

EU 개정 제조물책임지침 전환 시한 — 소프트웨어·AI를 제품으로

2027. 12. 2.

EU 고위험 AI 의무 적용(부속서 Ⅲ)

한국 사전 골격은 세웠으나 손해배상·증명 특칙 없음. 계도 기간은 법령상 유예가 아닌 행정 방침

미국 연방 포괄법 없음. 콜로라도 AI법 폐지·대체(2027. 1. 시행). 책임은 소송으로 형성 중

10 알고리즘 규제와 인간 존엄

존엄은 AI의 결정을 다툴 수 있을 때 지켜진다

헌법 제10조 — 인간을 데이터로 환원해 수단으로 취급하지 않는다(객체 금지)

1 **인지권**
AI의 영향을 받고 있음을 알 권리

2 **설명요구권**
주요 기준·핵심 요소를 이해 가능한 수준으로

3 **이의제기권**
오류·편향·사실 누락을 다툴 권리

4 **인간 재검토권**
실질 권한 있는 사람의 재판단

5 **비차별권**
직접·간접 차별로부터의 보호

6 **구제권**
신속한 시정·복구·배상

현행 개인정보 보호법 제37조의2는 「완전히 자동화된 결정」에만 작동 — 사람이 형식적으로 한 번 개입하면 권리가 사라진다

규제의 기준은 기술의 이름이 아니라, 인간에 대한 권력의 강도

실질적 인간 감독의 4요건

1. AI 판단을 번복할 권한과 정보
2. 검토에 충분한 시간과 자원
3. 번복 비율 등 실질성 지표의 기록
4. AI의 한계·오류 유형에 대한 훈련

「형식적 클릭은 감독이 아니다」

규제도 헌법의 통제를 받는다

위험 비례: 생명·신체·사회적 배분은 사전 평가, 저위험 도구는 표시와 사후 시정

과잉금지·명확성: 「고영향」「중대한 영향」은 불확정 개념 — 위임의 구체성이 규범통제의 쟁점

계층형 투명성: 대중·당사자·법원에 공개 수준을 달리해 영업비밀과 조화

장문의 특별법보다, 기존 법률에 넣을 짧은 조문이 실효적이다

1	**제조물 정의 보완**	소프트웨어·AI 시스템을 제조물로, 업데이트·재학습으로 생긴 결함도 포함
2	**고영향 영역 추정 조항**	위험관리·감독·기록 의무 이행을 증명 못 하면 과실·결함 추정(반증 가능)
3	**문서제출·비공개 심리 특칙**	모델 개요·평가·로그 제출, 영업비밀은 비밀유지명령으로 보호
4	**자동화 결정 재심사 효과**	거부 시 효력 정지와 인간 재처리 기한, 「실질 심사」 기준
5	**선보상 기금의 영역별 확장**	자율주행의 선보상-후구상 모델을 의료 AI·고위험 산업제어로

보험·기금·구상의 삼층 구조와 기업의 기록

3층 공적 보전기금

원인 불명의 잔여 손해

2층 사업자 상호기금·재보험

고영향 AI 사고

1층 영역별 강제보험

자동차·실외이동로봇 → 의료 AI 등으로 확장

보험자는 구상으로 실제 의무 위반자에게 비용을 되돌리고, 요율에 인증·사고 이력을 반영해 예방 유인을 가격에 내장

기업: 책임을 줄이는 것은 책임조항이 아니라 운영기록

- AI 시스템 목록화와 고영향 해당 여부 분류
- 모델·버전·프롬프트·입출력·승인 로그 보존
- 인간 감독자 지정, 번복 권한, 교육
- 공급 계약: 변경 통지·로그 제공·사고 협력
- **사고 시 첫 조치는 원인 추정이 아니라 증거 동결 — 기록을 덮어쓰는 업데이트 금지**

14 단계별 로드맵

실체 책임의 가중보다 증명의 재배분이 먼저다

단기 1년 이내

- 기본법 하위규범 정밀화, 기록 보존 기준 통일
- 소송 서면 AI 사용 고지·허위 인용 제재
- 「완전 자동화」 해석 지침, 판결문 공개 확대

중기 1~3년

- 제조물 책임법 개정
- 고영향 추정 조항, 문서제출 특칙
- AI 사고조사 기구, 독립 편향 감사
- 알고리즘 노무관리 투명성

장기 3~5년

- 고위험 AI 위험책임·의무보험
- 조직 위험관리 의무 연계 책임
- 잔여 손해 보전기금, 사회안전망 재원

※ AI 법인격 부여와 일반적 무과실책임의 전면화는 그다음 — 서두를 필요가 없다

결론

법의 과제는 기계를 처벌하는 것이 아니라, 가려진 인간과 조직의 의무를 다시 보이게 하는 것

1

증명

기록·제출·추정으로 정보 비대칭 교정

2

보험

선보상-후구상으로 신속한 구제

3

존엄

설명·이의·인간 재검토를 실질적 권리로

「결정의 이익을 누리는 자에게, 그 결정의 위험을 보이게 만드는 것」

감사합니다