GLOBAL HR FORUM
글로벌인재포럼 2026

원칙에서 실행으로 :
네이버의 서비스 중심 AI Safety Framework

송대섭

NAVER AI Safety Policy 리더

교육부 한국경제신문 KRIVET 한국직업능력연구원

일상과 서비스의 기반이 된 AI

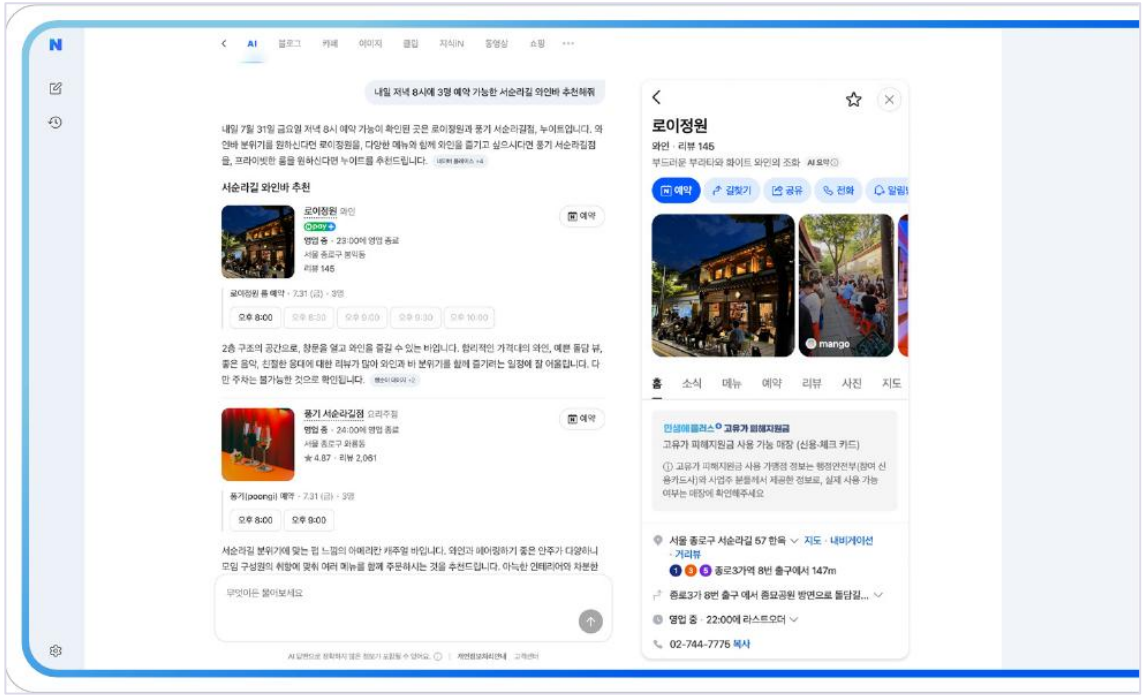
- AI가 새로운 기술을 넘어, 사람들의 일상과 업무를 지원하는 보편적인 도구로 자리매김. 서비스와 산업을 움직이는 기반
- AI가 정보를 제공하는 단계를 넘어 사용자를 대신해 행동하는 에이전트로 발전 → AI 네이티브 전환 가속화

→ **AI 네이티브 전환이 가속화되면서 AI가 사람과 사회에 미치는 영향도 더욱 넓고 복합적으로 변화**

→ AI Safety의 범위와 역할, 요구사항도 변화

AI Safety는 AI 네이티브 전환을 위한 핵심 전제 조건

네이버의 대화형 AI 검색 'AI탭'



- 2026년 6월 정식 출시 후 한 달 내 누적 사용자 1,000만명.
- AI탭에 이어 다양한 분야에 특화된 버티컬 에이전트 출시 예정

AI를 둘러싼 사회의 다양한 요구

AI 서비스를 안심하고 이용하고 싶다는 사용자의 요구와 AI 안전에 대한 사회의 우려는 일찍부터 제기

사용자	**믿고 쓸 수 있는 AI 서비스**, 눈 높이에 맞는 설명
사회 구성원	**생명·안전**, **차별**, 프라이버시에 대한 **우려**
학계·전문가	신뢰성에 대한 연구와 문제 제기
국제사회	AI 서울 정상회의(2024) 등 국제적 약속
제도	인공지능기본법(2026.1 시행) 등 최소 기준의 제도화

기업의 역할 **사회의 다양한 요구들을 서비스 현장에서 작동하는 체계로 구현**

2018년부터 AI 윤리·안전에 대한 요구에 대응



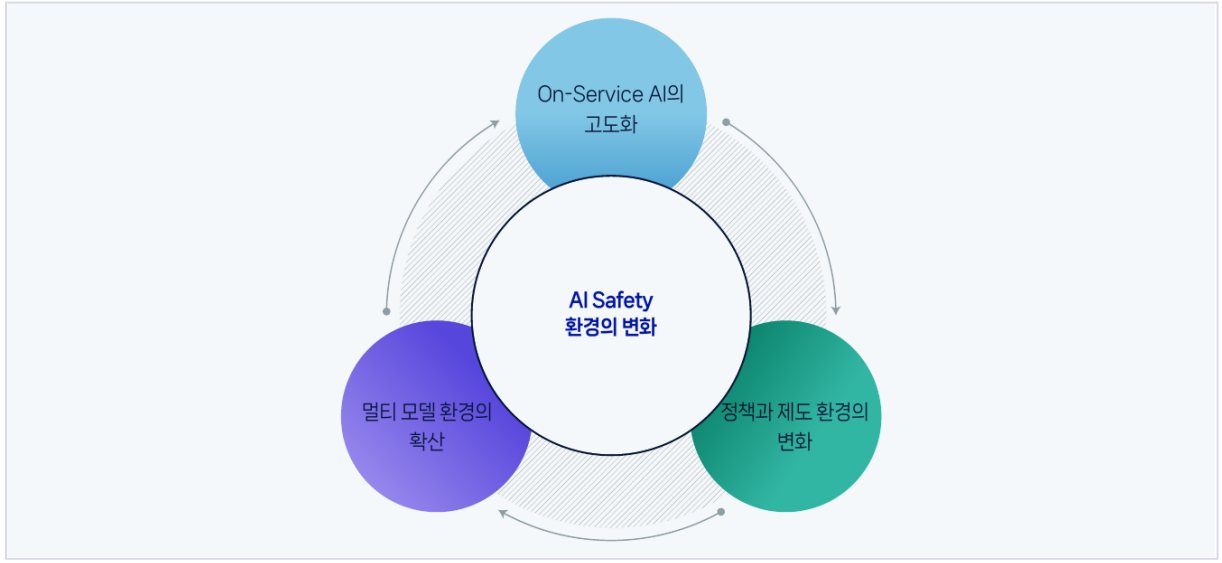
2021 AI 윤리 준칙 공개
사회적 요구와 산업적 관점 통합

2024 NAVER ASF 공개
AI 서울 정상회의 합의 사항 이행

2026 ASF 2.0, CHEC 2.0 개정
AI 네이티브(AI Native) 전환 대응

AI Safety가 선언적 원칙에 그치지 않고, 구체적인 기준과 실행 체계로 발전

AI Safety의 관리범위를 모델에서 서비스까지 확장



하나의 서비스 안에서 다양한 모델과 도구가 결합되면서 AI가 사람과 사회에 미치는 영향도 더욱 넓고 복합적으로 변화

ASF Beta (2024)
AI 모델이 위험 임계치에 도달했는가

ASF 2.0 (2026)
AI 서비스가 이용자와 사회에 어떤 영향을 줄 수 있는가

AI Safety는 하나의 모델을 안전하게 만드는 문제를 넘어,
여러 AI 모델과 기술이 결합된 서비스를 수천만 명의 사용자가 안심하고 이용할 수 있도록
어떻게 설계하고 운영할 것인가의 문제로 확장

사용자가 만나는 AI 서비스의 안전을 관리하는 체계

원칙·프레임워크·실행 체계로 구성

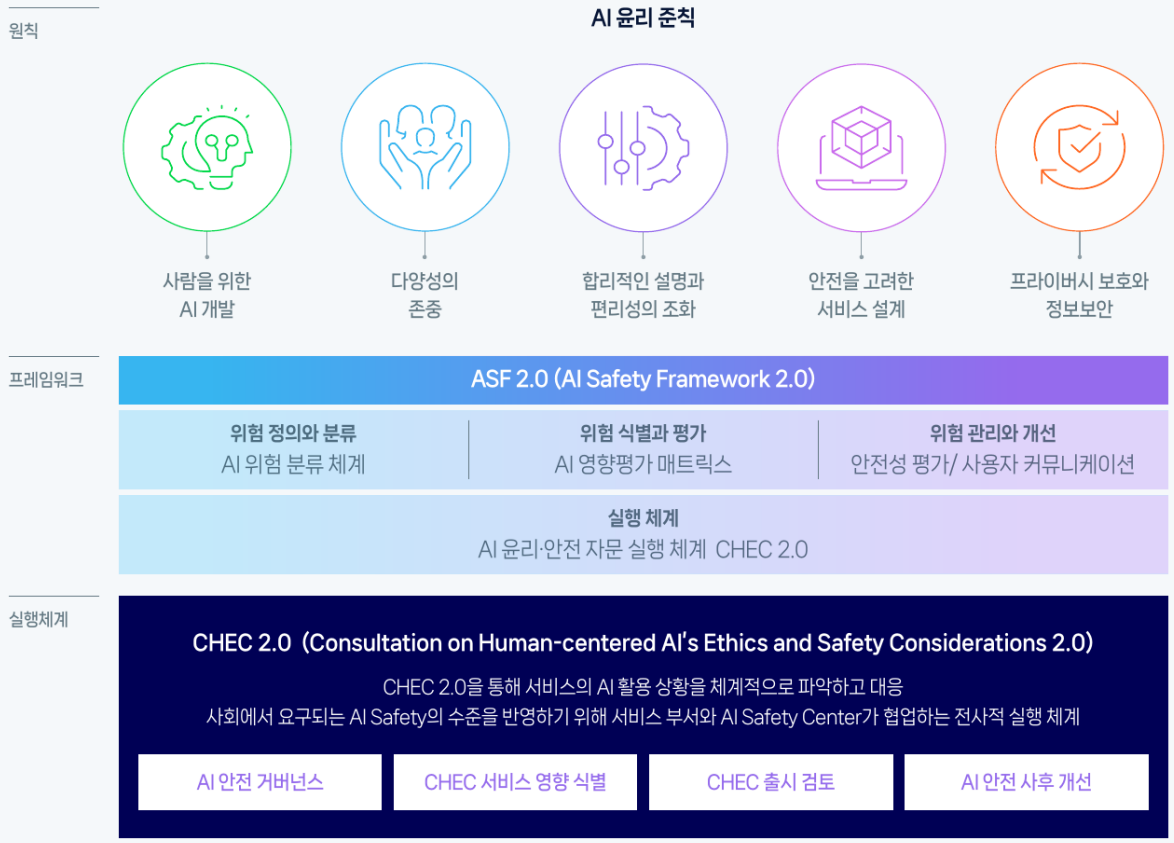
- AI 윤리 준칙(원칙)을 기반으로 수립된
- ASF 2.0(프레임워크)를 통해 AI 서비스의 위험을 분류·평가·관리하고
- CHEC 2.0(실행체계)를 통해 서비스 전 주기에서 AI Safety 실행

CHEC 2.0

사회에서 요구되는 AI Safety의 수준을 반영하기 위해 서비스 부서와 AI Safety Center가 협업하는 전사적 실행 체계

On-Service AI 관점에서 사용자가 실제로 만나는 AI 서비스의 안전을 관리하는 체계

AI 윤리 준칙을 기반으로 수립된 NAVER AI Safety Framework(ASF)를 통해, AI 서비스의 위험을 분류·평가·관리하고,
서비스 전 주기에서 AI Safety를 실행합니다.



사회가 지켜 온 가치를 AI 위험 판단 기준으로 설정

보호 대상과 보호 가치를 조합해 AI 서비스에서 발생할 수 있는 위험 유형화

ASF 2.0이 보호하고자 하는 대상



ASF 2.0이 보호하고자 하는 가치



ASF 2.0 보호 대상 및 가치에 따른 AI 위험 분류 체계 (AI Risk Taxonomy)

보호 가치 \ 보호 대상	사용자	사회 구성원	AI 서비스 생태계
생명과 신체의 보호	사용자 생명과 신체의 보호	사회 구성원 생명과 신체의 보호	AI 서비스 생태계 생명과 신체의 보호
경제적 가치의 보호	사용자 경제적 가치의 보호	사회 구성원 경제적 가치의 보호	AI 서비스 생태계 경제적 가치의 보호
부당한 차별 방지	사용자 부당한 차별 방지	사회 구성원 부당한 차별 방지	AI 서비스 생태계 부당한 차별 방지

AI 위험 분류 체계는 서비스의 활용 맥락에서
어떤 위험을 검토해야 하는지를 안내해 주는 출발점

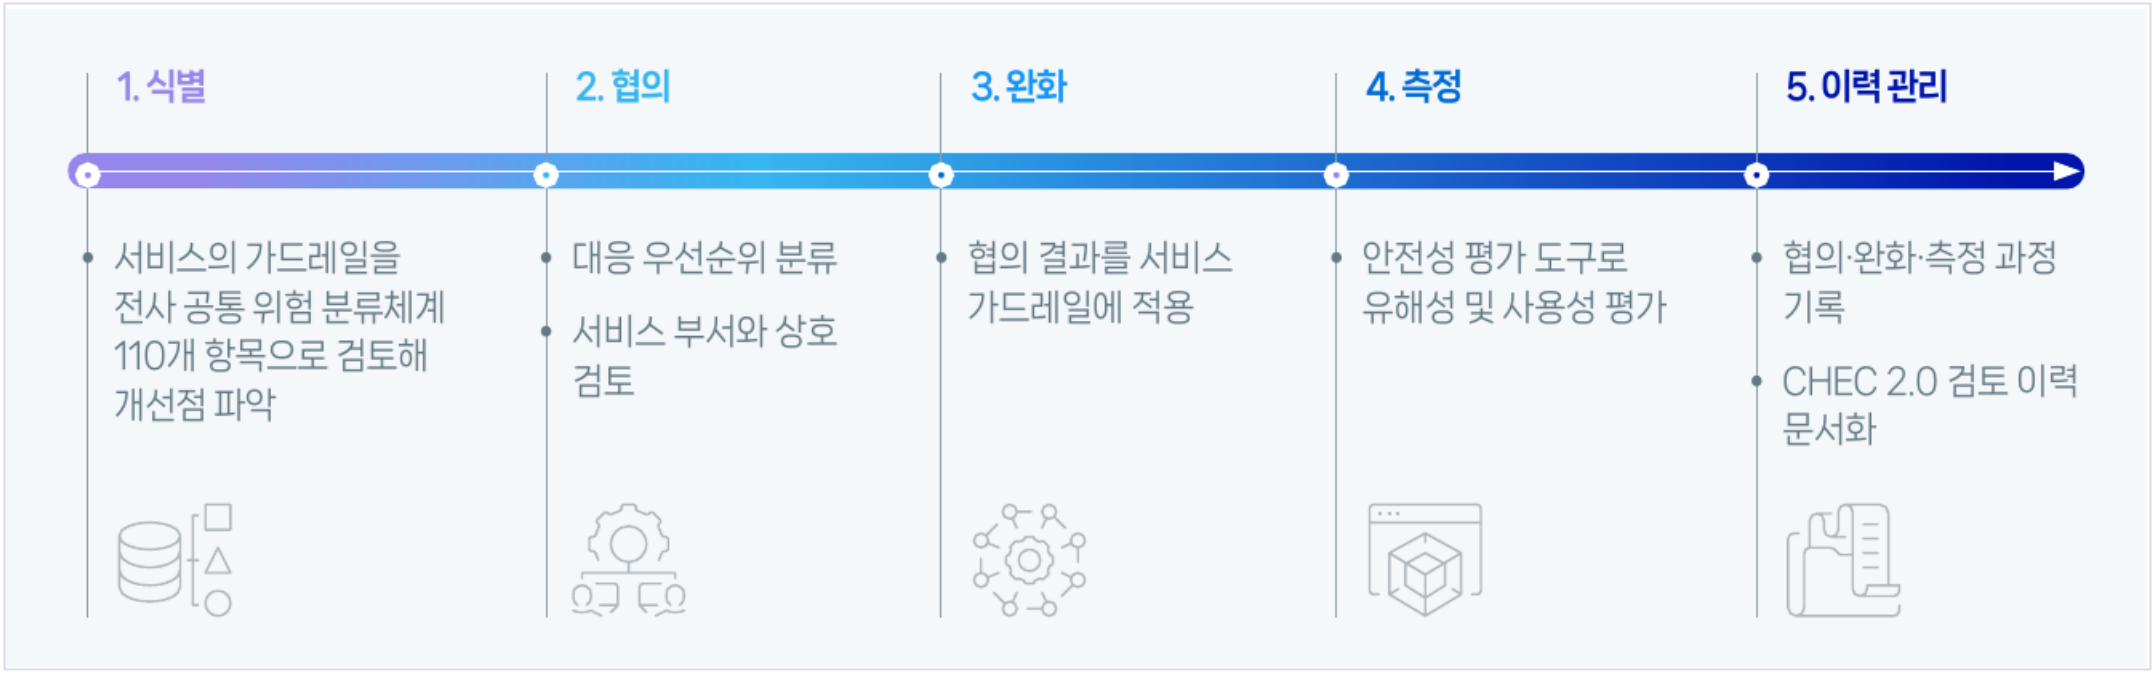
AI 서비스의 위험을 110개 항목으로 구체화

네이버 AI 위험 분류·식별 체계
(N-ARTI, NAVER AI Risk Taxonomy & Identification)

- 국제 범용 기준이 담지 못하는 한국 사회·문화의 민감 주제 반영
- 검색이라는 일상적 경로로 AI를 접하는 미성년자·고령층 보호까지 함께 반영

AI 서비스 가드레일 5단계 상담 프로세스

- 전사 공통 위험 기준(N-ARTI)을 바탕으로, 생성형 AI 출력의 경계를 미리 정하는 AI 서비스 가드레일 상담 프로세스 도입
- 협의를 통해 서비스 부서의 개별적 특성 반영

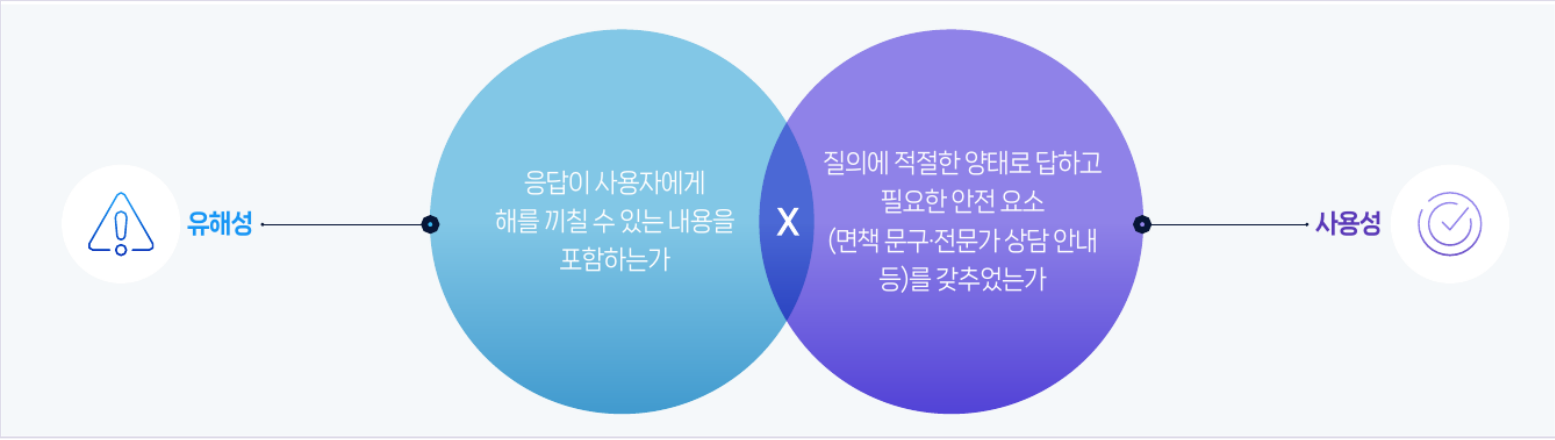


AI 안전성 평가시 유해성·사용성 함께 평가

네이버 AI 안전성 평가 도구
(N-ASET, NAVER AI Safety Evaluation Toolkit)

AI 서비스 응답을 유해성과 사용성이라는
두 가지 관점에서 평가

안전성을 확보하면서도
사용자 경험을 저해하지 않도록
응답 품질 개선



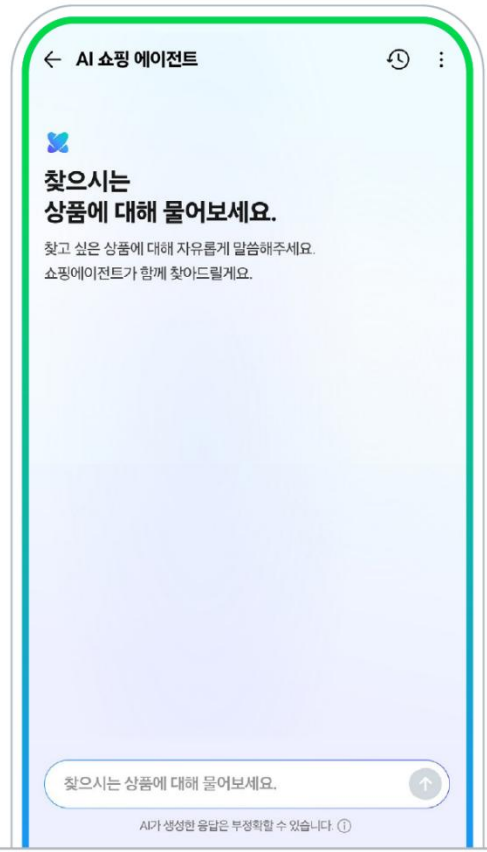
- 단순히 고정된 거절문구로 답변하는 것이 아니라, 상황에 맞는 답변을 생성하는 지 평가
- 면책 문구 분석시, 과소 대응 뿐 아니라 과잉 대응 또한 개선 대상으로 관리
- 사전 평가, 정기 평가 투 트랙으로 운영.

사용자의 눈높이에 맞춘 AI 관련 정보 제공

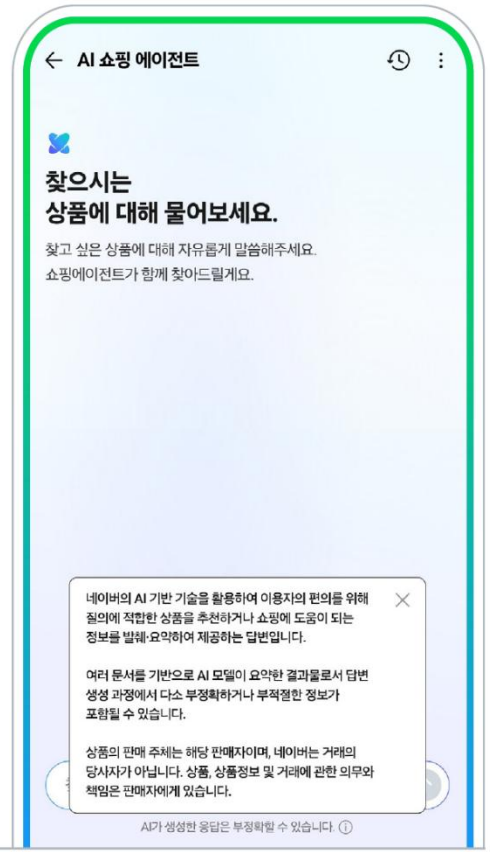
합리적인 설명과 편리성의 조화

(네이버 AI 윤리 준칙)

- 사용자에게 설명이 필요한 경우에는 AI 서비스를 쉽게 이해할 수 있도록 사용자의 눈높이에 맞춰 정보를 제공
- 구체적으로 서비스의 타이틀에 **AI 단어와 함께 On-Service AI 로고를 기재**하여, 사용자에게 해당 서비스가 생성형 인공지능이 활용되는 서비스라는 점에 대해 한 눈에 알 수 있도록 정보 제공
- 사용자가 알아두면 좋을 정보도 **하단의 툴팁을 통해 상세히 설명**



AI 쇼핑 에이전트 화면



AI 쇼핑 에이전트 툴팁 화면

CHEC 2.0으로 서비스의 AI 활용 상황 파악 및 대응

ASF 2.0의 세 가지 축이 개별 서비스의 맥락에서 구체적으로 실행되도록 연결

위험 정의와 분류

AI 위험 분류 체계
(AI Risk Taxonomy)

위험 식별과 평가

AI 영향 평가 매트릭스
(AI Impact Assessment Matrix)

위험 관리와 개선

안전성 평가
사용자 커뮤니케이션

AI 위험을 다루는
기준과 절차 정의

실행 체계

AI 윤리·안전 자문 실행 체계
(Consultation on Human-centered AI's Ethics and Safety Considerations, **CHEC 2.0**)

해당 기준과 절차가 서비스
전 주기에서 일관되게 적용
되도록 하는 역할 수행

- 개별 서비스 부서에서 AI Safety를 실행할 수 있도록 가이드 제공
- AI 윤리와 함께 AI Safety에 대한 사항 점검
- AI 모델과 서비스에 대한 안전성 그리고 인공지능 생성물에 대한 사용자 커뮤니케이션 강화

AI Safety 3계층(layer) 관리 감독 체계 구축

구분	담당 부서	주요 역할
실행 (layer 1)	서비스 실무 조직	AI 서비스의 기획 및 운영과 모델 개발을 진행하는 과정에서 AI Safety Center의 가이드에 따라 ASF 2.0을 실행합니다.
관리 및 지원 (layer 2)	CRO (리스크관리워킹그룹)	AI Safety Center는 다양한 부서의 관점을 통합하며, 회사 전체의 AI Safety 업무를 전담합니다. 또한 전담 조직으로서의 독립성과 함께 실행 조직이 ASF 2.0을 실천하는 과정에서 AI Safety를 구체적으로 구현할 수 있도록 AI Safety 관리 및 교육을 지원하고 있습니다.
	AI Safety Center	
감독 및 최종 의사결정 (layer 3)	이사회 (리스크관리 위원회)	이사회는 ASF 2.0이 관리 및 감독하고자 하는 AI Safety 관련 사항에 대한 최종적인 의사결정 기구입니다.

2026.3
AI Safety Center 재편

서비스 조직이 안전 조치를 실행하고,

AI Safety Center가 이를 관리·지원하며,

이사회가 감독하고 주요 사항을 최종 결정

AI탭 설계부터 출시까지 전 과정에서 AI Safety 협업



서비스 조직과 AI Safety Center가 답변 원칙·안전 장치 함께 설계…CHEC 2.0 자문 통해 AI Safety 점검

학계, 정책 및 산업계와 함께 AI Safety 관련 논의

AI 서비스 관리 체계의 객관성과 신뢰성을 높이기 위해 ISO 42001 인증 추진

01

학계 및 정책 협업

주요 대학과 AI 기술 및 안전성 연구를 협업. 서울대학교 인공지능 정책 이니셔티브(SAPI) 등을 통해 AI 정책 분야에서 협력

02

국내외 안전 네트워크

인공지능 안전 연구소, 한국정보통신기술협회 등 국내 기관 그리고 UN Global Compact 등 국제 네트워크와 협력

03

ISO/IEC 42001 인증 추진

AI 서비스 관리 체계의 객관성과 신뢰성을 높이기 위해 AI 경영시스템 국제 표준인 ISO/IEC 42001 인증 추진

AI 업계가 요구하는 안전 장치는 ISO/IEC 42001의 접근과 유사

앤트로픽 CEO가 제안한 안전 프레임워크는 '외부 검토'와 '공통 기준'을 전제

→ ISO 42001이 작동하는 방식과 같은 구조

혁신의 기반이 되는 AI Safety



『NAVER AI Safety Progress Report 2026』 2026.9.16

사회가 요구하는 AI 안전의 기준을, 서비스 현장에서 작동하는 체계로 구현

AI Safety를 혁신을 제한하는 조건이 아니라,
더 많은 사람들이 AI를 신뢰하고 적극적으로 활용하게 하는
혁신의 기반으로 발전시키겠습니다.

AI Safety를 혁신의 기반으로 발전시키는 과정과 경험을 사회와 지속적으로 공유하겠습니다

글로벌인재포럼 2026

EVERYTHING AI, 지속가능을 위한 길

EVERYTHING AI, The Path to Sustainability